SIMULATION DE TARIFICATION ACTUARIELLE

PROJET DE DÉMONSTRATION – ASSURANCE AUTOMOBILE

Préparé par
Steve Soro
Analyste senior indépendant
en données et intelligence
d'affaires

Document fourni à des fins de démonstration méthodologique uniquement.
Ne contient aucune donnée réelle ni confidentielle.

1. Contexte et objectif du projet

Ce document présente une **simulation de modélisation de tarification automobile**, élaborée selon une démarche actuarielle standard, conforme aux pratiques usuelles du marché **P&C (Property & Casualty)**.

L'étude repose **exclusivement sur des données fictives**, générées à des fins pédagogiques et démonstratives. Elle ne contient **aucune donnée confidentielle, ni d'employeur ni de client**.

L'objectif est d'illustrer une démarche actuarielle **reproductible**, sans divulgation d'informations sensibles, et de démontrer nos capacités d'analyse et de modélisation.

La chaîne analytique suivie reflète les étapes classiques d'un mandat de tarification :

- Nettoyage et préparation des données
- Analyse exploratoire et unidimensionnelle
- Sélection et transformation des variables
- Modélisation et validation
- Simulation et production des résultats.

Ce type de démarche est applicable à divers contextes : tarification automobile ou habitation, segmentation de portefeuille, ajustements tarifaires, analyses de sensibilité ou développement d'outils actuariels d'aide à la décision.

2. Nettoyage et préparation des données

Une analyse exploratoire approfondie a été menée afin d'identifier les **incohérences, les valeurs aberrantes et les anomalies de saisie** susceptibles d'affecter la qualité des résultats.

Les principales corrections apportées incluent :

- **Harmonisation des modalités catégorielles** (ex. correction de valeurs telles que *"M"*, *"Yes"*, *"No"* pour les modalités attendues *"H"*, *"Oui"*, *"Non"*).
- **Correction d'erreurs de saisie manifestes**, notamment pour le nombre d'enfants et l'âge du véhicule.
- **Traitement d'incohérences comptables**, incluant des valeurs négatives d'« encouru » ou des profils présentant un nombre de sinistres nul malgré la présence d'un volume de risque et d'un « encouru » non nul.
- **Interpolation linéaire ciblée** pour corriger une omission du nombre de sinistres, sur la base de profils comparables.

Recommandation
L'analyse met en évidence l'importance de mécanismes de contrôle en amont (listes déroulantes, règles de validation des données) afin de prévenir la réapparition de ce type d'anomalies dans un contexte opérationnel.

3. Analyse unidimensionnelle : fréquence, sévérité et prime pure

Cadre méthodologique

Les indicateurs sont définis selon les conventions actuarielles usuelles :

- **Exposition ($\sum E_i$)** : volume d'assurés (base du risque)
- **Sinistres ($\sum N_i$)** : nombre total d'évènements
- **Coûts ($\sum S_i$)** : montant total payé
- **Fréquence** :

$$\mathrm{Freq} = \frac{\sum \mathrm{N_i}}{\sum \mathrm{E_i}}$$

- **Sévérité** :

$$\mathrm{Sev} = \frac{\sum \mathrm{S_i}}{\sum \mathrm{N_i}}$$

- **Prime pure** :

$$\mathrm{PP} = \mathrm{Freq} \times \mathrm{Sev} = \frac{\sum \mathrm{S_i}}{\sum \mathrm{E_i}}$$

Les montants sont exprimés en **dollars canadiens**.

Transformations testées

Pour chaque variable, plusieurs transformations usuelles ont été évaluées :

- Inverse
- Logarithmique
- Carrée
- Exponentielle
- Racine carrée.

Les transformations améliorant la tendance ou la linéarité ont été retenues lorsque c'était pertinent. À défaut, les variables ont été conservées dans leur forme initiale.

Cette analyse a permis :

- d'identifier les variables présentant un **pouvoir prédictif significatif**,
- de détecter des **effets non linéaires**,
- et de repérer certains **segments atypiques**.

4. Modélisation et sélection du modèle optimal

Plusieurs modèles de **régression multiple et de modèles linéaires généralisés (GLM) additifs, multiplicatifs, séparés ou combinés** ont été comparés, notamment :

- GLM Gamma (lien log),
- modèles de type Poisson,
- variantes intégrant des transformations et des variables indicatrices.

Les critères de sélection combinent :

- tests de significativité statistique (ANOVA, statistique F, valeurs p),
- indicateurs de qualité d'ajustement (R^2 et R^2 ajusté),
- critère de parcimonie via l'**Akaike Information Criterion (AIC)**.

La démarche de sélection s'est déroulée en trois étapes :

1. Modèles sans transformation,
2. Introduction de variables indicatrices pour certaines variables numériques discrètes,
3. Combinaison des transformations retenues et des indicatrices.

La sélection finale repose sur un compromis entre **qualité d'ajustement, stabilité et interprétabilité**. La procédure *stepwise* a permis d'identifier un sous-ensemble pertinent de variables, la sélection finale reposant sur des critères statistiques et sur le jugement actuariel.

Les postulats du modèle ont été validés à l'aide :

- des résidus « studentisés »,
- de graphiques de dispersion,
- d'un histogramme des résidus,
- et d'un Q-Q plot normal.

Des transformations supplémentaires ont été introduites pour corriger des écarts résiduels, ce qui a conduit à un ajustement jugé satisfaisant.

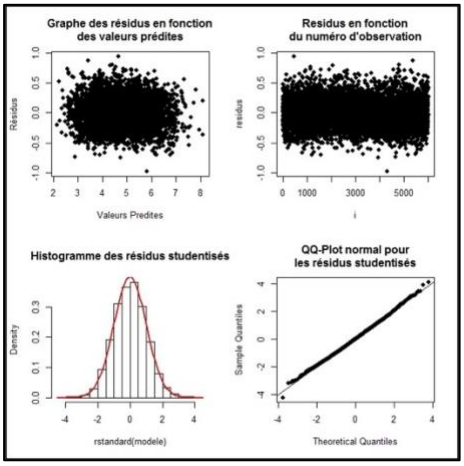

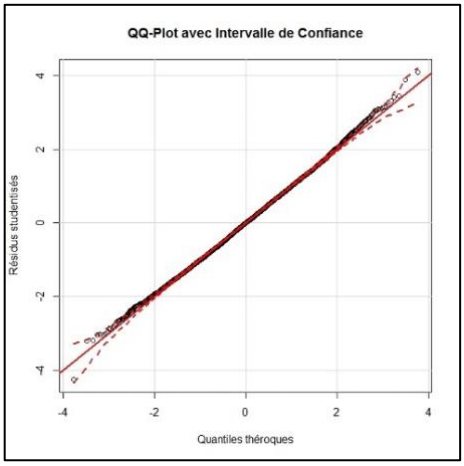

5. Résultat et utilisation du modèle

Le modèle retenu permet de :

- prédire la **prime pure ajustée** pour chaque profil de risque,
- produire des prévisions cohérentes autour de la moyenne observée,
- identifier une perte de précision progressive en queue de distribution, phénomène attendu en tarification.

Le modèle a ensuite été utilisé pour **simuler la prime pure de nouveaux profils** pour une année ultérieure, illustrant son usage opérationnel dans un contexte de tarification.

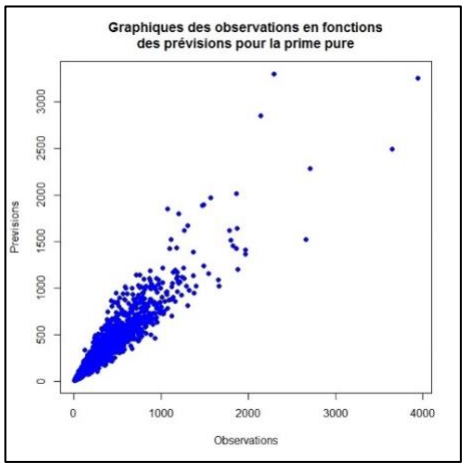

6. Conclusion

Cette simulation illustre une **démarche actuarielle complète et structurée**, de la préparation des données à la production de résultats exploitables pour la prise de décision.

Elle démontre nos capacités à :

- structurer des données complexes,
- appliquer des méthodes actuarielles rigoureuses,
- construire des modèles interprétables,
- et traduire les résultats en informations utiles pour la tarification et la gestion du risque.

Note
Ce document est fourni **exclusivement à des fins de démonstration méthodologique**. Une version plus détaillée peut être présentée dans un cadre privé ou professionnel.

Préparé par Steve Soro – Analyste senior indépendant en données et intelligence d'affaires
Projet de démonstration – ne contient aucune donnée confidentielle